

ESCUELA POLITÉCNICA NACIONAL
ESCUELA DE FORMACIÓN DE TECNÓLOGOS

PROYECTO DE FIN DE SEMESTRE
ANÁLISIS DE DATOS

PROFESOR:	Ing. Juan Pablo Zaldumbide
PERÍODO ACADÉMICO:	2026-A
FECHA DE ENTREGA:	___ / ___ / 2026
PESO:	35% de la nota final

1. Objetivo general

Diseñar, implementar y defender una solución integral de análisis de datos que combine Python, KNIME y Power BI para extraer, limpiar, transformar, integrar, modelar, analizar y visualizar información proveniente de múltiples fuentes, generando conclusiones útiles para la toma de decisiones.

2. Nivel de dificultad actualizado

Este proyecto mantiene la estructura del proyecto 2025-A, pero eleva moderadamente el nivel técnico mediante automatización, validación de calidad de datos, modelado analítico reproducible, integración KNIME-Python y dashboards con indicadores accionables.

3. Herramientas obligatorias

Herramienta	Uso mínimo obligatorio	Evidencia esperada	Peso técnico sugerido
Python	Extracción, limpieza avanzada, validación, análisis exploratorio y/o modelado básico.	Notebooks .ipynb, scripts .py, requirements.txt y datasets procesados.	35%
KNIME	Workflow ETL completo con lectura, limpieza, combinación, transformación y exportación.	Archivo .knwf o capturas del workflow, nodos documentados y ejecución reproducible.	30%
Power BI	Modelo de datos, medidas DAX, visualizaciones, segmentadores y narrativa ejecutiva.	Archivo .pbix, capturas del dashboard y explicación de decisiones.	35%

4. Caso de estudio

Cada grupo seleccionará un problema real de análisis de datos. El proyecto debe integrar al menos 6 fuentes de datos relacionadas con una temática principal y, cuando sea posible, con contexto ecuatoriano.

- Tráfico, movilidad, transporte público, siniestros o congestión urbana.
- Turismo, restaurantes, eventos, conciertos y sitios de esparcimiento.
- Deportes, rendimiento, asistencia, resultados o comportamiento de aficionados.
- Noticias, redes sociales, opinión pública o análisis de sentimiento.
- Educación, empleo, economía familiar, emprendimientos o consumo.
- Salud pública, ambiente, clima, seguridad ciudadana u otra temática aprobada por el docente.

5. Requisitos técnicos mínimos

1. Usar al menos 6 fuentes de datos. Mínimo 3 deben ser reales y verificables; las demás pueden ser complementarias, generadas o enriquecidas.
2. Integrar datos estructurados y semiestructurados: CSV/Excel, JSON/API, base de datos SQL o archivo plano exportado.
3. Trabajar con al menos 2'500.000 registros acumulados. Para nota máxima se recomienda superar 2'000.000 de registros.
4. Crear un proceso ETL reproducible en KNIME que incluya limpieza, normalización, unión de tablas y exportación final.
5. Crear al menos un notebook o script en Python para EDA, limpieza avanzada, validación de calidad o modelado analítico.
6. Construir un modelo en estrella o modelo tabular en Power BI con tabla de hechos, dimensiones y relaciones correctamente definidas.
7. Implementar mínimo 8 medidas DAX, incluyendo indicadores de tendencia, ranking, variación porcentual y KPI principal.
8. Aplicar análisis de sentimiento si el caso contiene texto; si no contiene texto, aplicar una técnica alternativa: clustering, scoring, predicción simple, detección de anomalías o segmentación.
9. Documentar el diccionario de datos y las reglas de transformación aplicadas.
10. Publicar el proyecto en GitHub con estructura organizada y README técnico.

6. Requisitos de calidad de datos

- Identificar valores nulos, duplicados, inconsistencias, outliers y formatos incorrectos.
- Crear una tabla o reporte de calidad antes y después de la limpieza.
- Definir reglas de limpieza justificadas: eliminación, imputación, estandarización, conversión de tipos y tratamiento de outliers.
- Validar que las llaves, relaciones y agregaciones sean coherentes antes de construir el dashboard.
- Incluir al menos 5 pruebas de validación: conteo de registros, rangos válidos, unicidad, integridad referencial y consistencia de fechas.

7. Arquitectura esperada

La arquitectura debe evidenciar el flujo completo de datos: fuentes -> extracción -> staging -> limpieza -> integración -> modelo analítico -> visualización -> conclusiones.

- Capa de fuentes: archivos CSV/Excel, APIs, JSON, bases SQL, web scraping permitido solo si respeta términos de uso.
- Capa de procesamiento: KNIME como flujo principal y Python como soporte analítico/automatización.
- Capa de almacenamiento: carpeta data/raw, data/processed y, opcionalmente, SQLite/PostgreSQL/MySQL.
- Capa de visualización: Power BI con modelo relacional, medidas DAX y dashboards explicativos.
- Capa de documentación: informe IEEE, README, diccionario de datos, capturas y videos.

8. Dashboards y preguntas de análisis

El dashboard debe responder al menos 12 preguntas o casos de análisis. No basta con mostrar gráficos: cada visualización debe apoyar una conclusión o recomendación.

- Mínimo 4 páginas de dashboard: resumen ejecutivo, exploración, análisis detallado y conclusiones/recomendaciones.
- Mínimo 10 visualizaciones útiles y no repetitivas.
- Mínimo 4 segmentadores relevantes: fecha, ubicación, categoría, fuente, grupo, producto, evento u otro.
- Mínimo 3 KPIs principales con interpretación.
- Cada página debe incluir una breve narrativa: qué se observa, por qué importa y qué decisión permite tomar.

9. Entregables

Entregable	Contenido mínimo	Porcentaje
Informe IEEE doble columna	Caso de estudio, objetivos, arquitectura, fuentes, ETL, calidad de datos, análisis, visualizaciones, resultados, conclusiones, recomendaciones, problemas encontrados y link GitHub.	25%
Proyecto técnico en GitHub	Scripts Python, notebook, workflow KNIME, archivo Power BI, datasets de muestra o instrucciones de descarga, README, requirements.txt y estructura de carpetas.	25%
Dashboard Power BI	Modelo de datos, medidas DAX, páginas de dashboard, KPIs, filtros, narrativa y conclusiones accionables.	20%
Videos explicativos	Video 1: proceso de datos y ETL. Video 2: análisis del dashboard y conclusiones. Cada video de 4 a 6 minutos.	15%
Defensa individual	Presentación técnica de 15 a 20 minutos por grupo. Preguntas individuales sobre código, KNIME, Power BI, datos y decisiones tomadas.	15%

10. Herramientas.

Debe utilizar, en su arquitectura, al menos 2 bases de datos SQL y 2 NoSQL.

Python, Knime para el proceso de etl.

Power BI para las visualizaciones.

11. Rúbrica resumida

Criterio	Excelente	Bueno	Básico	Insuficiente
Integración de datos	10+ fuentes, flujo reproducible, datos reales y bien documentados.	Fuentes suficientes y flujo entendible.	Fuentes limitadas o integración parcial.	Datos aislados o no reproducibles.
Python	EDA, limpieza, validación y análisis/modelado bien explicado.	Scripts funcionales con limpieza y gráficos.	Uso básico o poco documentado.	No ejecuta o no aporta al proyecto.
KNIME	Workflow completo, ordenado, comentado y exportable.	Workflow funcional con nodos principales.	Workflow incompleto o poco claro.	No existe o no ejecuta.
Power BI	Modelo correcto, DAX sólido, narrativa y decisiones claras.	Dashboard funcional y entendible.	Gráficos básicos sin profundidad.	Dashboard incompleto o inconsistente.
Conclusiones	Basadas en evidencia, accionables y conectadas al caso.	Conclusiones razonables.	Conclusiones genéricas.	No hay análisis real.

Fuentes de datos (ejemplo)

Tipo	Cantidad mínima
APIs REST	4
Open Data	3
Web Scraping	1
Dataset (Kaggle, UCI, etc.)	2

12. Criterios de defensa individual

- Cada estudiante debe explicar su aporte específico y demostrar que comprende el flujo completo.
- El docente podrá solicitar la ejecución de un script, notebook, workflow KNIME o explicación de una medida DAX.
- Se evaluará la coherencia entre informe, repositorio, dashboard y exposición.

- El uso de IA está permitido como apoyo, pero el grupo debe comprender, adaptar y justificar todo el código y análisis presentado.

13. Recomendaciones para subir el nivel sin volverlo excesivo

- Agregar una métrica compuesta o índice propio del grupo.
- Comparar resultados por ciudad, fecha, categoría o segmento.
- Incluir una página de “calidad de datos” en Power BI.
- Usar Python para automatizar una parte repetitiva del proceso.
- Crear un pequeño modelo predictivo o de segmentación solo si aporta al caso de estudio.
- Mantener el enfoque en decisiones: qué problema se detectó y qué acción se recomienda.

Nota: la innovación, automatización, buena documentación y defensa técnica individual serán consideradas como plus para la nota final.

Arquitectura de referencia

